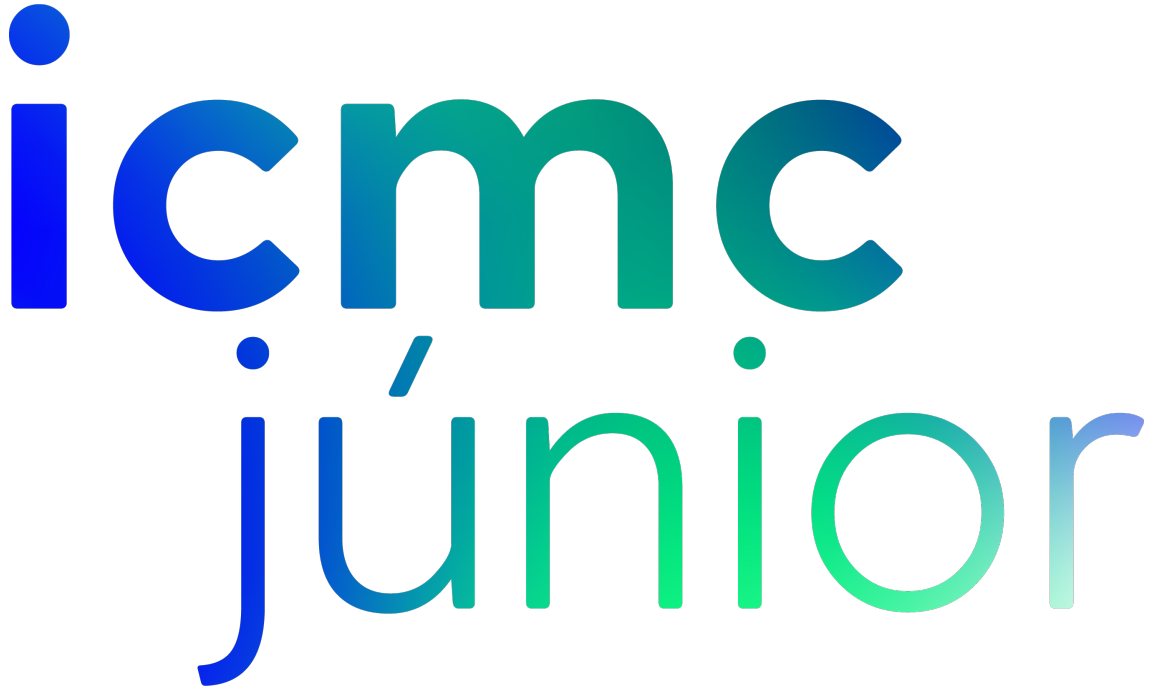
UNIVERSIDADE DO ESTADO DE SÃO PAULO



Neste documento, está descrito o Projeto Trainee para a área de estatística 2026.1.

DIRETORIA
Gabriel Menezes

Conteúdo

1 Contexto **2**

2 Base de Dados **2**

3 Recomendações **3**

3.1 Estudos 3

4 Escopo do Projeto **4**

5 Extras **4**



1 Contexto

Gustavo Verenato é um novo cliente da ICMC Júnior. Pós-doutorando em pedagogia infantil, em sua pesquisa, sua equipe e amigos acompanham 1000 alunos do ensino médio da cidade de São Carlos, para cada adolescente, é acompanhado e medido alguns fatores, como:

- Nota final;
- Pontuação em determinadas matérias;
- Tempo de sono diário;
- Tempo de tela diário;
- Tempo de atividade física;
- entre outros...

Durante anos e depois de muito trabalho árduo, coletaram dados suficientes das amostras e almejam, agora, concluir o trabalho.

Para isso, Gustavo quer uma análise profunda da relações entre as variáveis, O escopo exigido pelo Verenato está destacadao na seção 4.

2 Base de Dados

A base de dados é composta pelas seguintes colunas:

- student_id: Id do estudante;
- final_score: Pontuação final do estudante;
- grade: Pontuação categórica do estudante, sendo "A"a melhor;
- pass_fail: Se passou ou não de ano;
- previous_score: Pontuação do ano anterior;
- math_prev_score: Pontuação de matemática;
- science_prev_score: Pontuação de Ciência;
- language_prev_score: Pontuação em línguas;
- daily_study_hours: Quantas horas estuda por dia;
- attendance_percentage: Porcentagem de presença nas aulas;
- homework_completion_rate: Porcentagem de completude das tarefas de escola;
- sleep_hours: Quantidade de horas dormidas por dia;

- screen_time_hours: Tempo de tela diário;
- physical_activity_minutes: Minutos de atividade física diário;
- motivation_score: Nível de motivação escolar;
- exam_anxiety_score: Nível de ansiedade do estudante;
- parent_education_level: Nível de educação escolar dos pais;
- study_environment: Nível de ruído do ambiente.

3 Recomendações

Essa seção não faz parte da história criada. Utilize-a como seu guia para o que a diretoria quer de você.

Esse projeto tem como principal objetivo a sua evolução e seu aprendizado.

ATENÇÃO: Agora é o melhor momento para você aprender sobre as etapas fundamentais de um projeto de análise de dados, como também, análises corriqueiras e necessárias no mercado de trabalho. Seja CURIOSO, mudanças no escopo serão aceitas, desde que sejam implementadas outras análises que vocês, por si só, pensaram.

No caso de imaginarem uma análise que pode ser feita, que seja de dificuldade similar à análise que vai retirar do escopo (caso retire). Além disso, escreva em letra VERMELHA no relatório final essa mudança e explique-a.

3.1 Estudos

- Utilize a RocketSeat ou a Udemy para acessar aulas espetaculares sobre os assuntos;
- Pergunte para o coordenador do seu grupo a sua dúvida;
- Separe sua equipe igualmente, marquem reuniões e separem as etapas e prazos para concluir o projeto com êxito.

Leve os seguintes itens como um guia para facilitar o estudo dos tópicos para o projeto:

Obs.: Os itens que estiverem marcados com (!) não são, em grande parte, necessários caso você não aplique machine learning.

- Limpeza e tratamento de dados (técnicas para lidar com dados faltantes, outlier, formatações diferentes);
- (!) Engenharia de features (Tratamento de dados categóricos, criação de novas features, tratamento de datas, normalização e padronização);
- Análise exploratória e descritiva (Histograma, box-plot, gráfico de barras, gráfico de pontos);

- Testes estatísticos (shapiro-wilk, pearson, spearman, qui-quadrado);
- (!) Machine Learning básico (Regressão Linear).

4 Escopo do Projeto

Depois da negociação do projeto, foi definido os entregáveis, i.e., tarefas que são inegociáveis para entrega do projeto. São elas:

- Heatmap para visualização da correlação entre variáveis;
- Distribuição da variável "final score";
- Gráfico de pontos "final score"por "Attendance Percentage"; (*)
- Box plot "daily study hours"por "pass fail".
- Teste estatístico para verificação da hipótese gerada em (*), como shapiro-wilk, pearson ou spearman, entre outros.
- Relatório final que deve conter:
  - Objetivo do projeto;
  - Explicação de cada etapa do projeto;
  - Cada gráfico gerado, nas cores VERDE e AZUL;
  - Referências Utilizadas;
  - Hipóteses tiradas da análise estatística;
  - Script de comando para realização do teste estatístico;
  - Explicação matemática (se possível) de cada técnica utilizada, de maneira simples e intuitiva;
  - Conclusão/Resumo.

5 Extras

Além dos entregáveis, Gustavo ficaria **muito feliz** se fosse entregado algum dos seguintes adicionais:

- Verenato tem a curiosidade de saber se é possível prever alguma das seguintes variáveis alvo: "final score", "grade", "pass fail". Para isso, podemos utilizar as seguintes etapas:
  1. Pré-processamento dos dados;
  2. Separação dos grupos de teste e treino;
  3. Elaboração e treinamento do modelo.

Modelos recomendados:

  - Random Forest Classifier;
  - Decision Tree Regressor;
  - Linear Regression;
  - Multiple Linear Regression.

- Será que o grau de ansiedade tem relação com a nota final do estudante?

  Gustavo gostaria de responder essa pergunta de forma estatística e verificando sua significância.

  Recomendações:

  - Separe os seguintes grupos de ansiedade:
    $\{- < 4\} \rightarrow$ Baixa ansiedade;
    $\{3 < - < 8\} \rightarrow$ Média ansiedade;
    $\{7 < -\} \rightarrow$ Alta ansiedade.